



Dhia Gdara

Mini Projet

1ère GMAM

Introduction

Dans le cadre de ce mini-projet, nous nous intéressons à l'étude de plusieurs lois de probabilité fondamentales en statistique : la loi du khi-deux (χ^2), la loi de Student, la loi de Fisher, et la loi de Gamma. Ces lois jouent un rôle essentiel dans l'analyse et l'inférence statistique, notamment dans les tests d'hypothèses, l'estimation des paramètres et l'analyse de la variance.

Ce projet a pour objectif d'explorer les propriétés mathématiques et statistiques de ces lois, de comprendre leurs domaines d'application, et d'illustrer leur utilisation à travers des exemples concrets et des visualisations.

1-La loi du khi deux,

La loi du khi deux de paramètre $k \in \mathbb{N}^*$ est la loi de la somme de carrés de k lois normales centrées réduites mutuellement indépendantes.

En statistiques, cette loi trouve de nombreuses applications, notamment pour les tests du χ^2 qui permettent de calculer l'écart entre la distribution observée dans un échantillon avec une distribution théorique (**test d'ajustement**), de tester si les échantillons observés proviennent d'une même population (**test d'homogénéité**) et de tester si deux paramètres d'une population sont indépendants (**test d'indépendance**).

1-1 Définition de la loi du khi deux

a/Définition à l'aide de la loi normale

Soient k variables aléatoires mutuellement indépendantes $X_1, X_2, \dots, X_k$, qui suivent une loi normale centrée réduite, c'est-à-dire $N(0,1)$.

On pose :

$$X = \sum_{i=1}^k X_i^2$$

Alors X suit une loi du khi-deux de paramètre k , notée :

$$X \rightarrow \chi^2(k)$$

b/Définition à l'aide de la loi gamma

Pour tout $k \in \mathbb{N}^*$, la variable aléatoire X suit la loi $\chi^2(k)$ si et seulement si X suit la loi Gamma de paramètres $(k/2, 1/2)$, c'est-à-dire :

$$X \rightarrow \Gamma(k/2, 1/2)$$

1-2 Densité de probabilité

La densité de X est donnée par :

$$x \mapsto \begin{cases} (1 / (2^{k/2} * \Gamma(k/2))) * x^{(k/2) - 1} * e^{-x/2} & \text{si } x > 0 \\ 0 & \text{sinon} \end{cases}$$

1-3 Fonction de répartition

$$x \mapsto \begin{cases} (1 / \Gamma(k/2)) * \int(t = 0 \rightarrow x) t^{(k/2) - 1} * e^{-t} dt & \text{si } x > 0 \\ 0 & \text{sinon} \end{cases}$$

1-4 Espérance et variance

On a :

$$X = \sum_{i=1}^k X_i^2 \text{ avec } X_i \sim N(0,1)$$

Donc :

$$E(X) = \sum E(X_i^2) = \sum (\text{Var}(X_i) + (E(X_i))^2) = \sum (1 + 0) = k$$

$$\text{Var}(X) = \sum \text{Var}(X_i^2) = \sum (E(X_i^4) - E(X_i^2)^2) = \sum (3 - 1) = 2k$$

1-5 Test du khi-deux

Le test du Khi-deux est un **test d'hypothèse** utilisé pour déterminer s'il existe une relation entre deux **variables catégorielles**.

Qu'est-ce qu'une variable catégorielle? Les variables catégorielles sont, par exemple, le sexe, le journal préféré, la fréquence d'écoute de la télévision ou le niveau d'études le plus élevé d'une personne. Par conséquent, lorsque deux variables catégorielles doivent être testées pour déterminer s'il existe une relation, on utilise le test du khi-deux.

Variables catégoriques

Genre	Journal préféré	Fréquence de la télévision	Niveau d'études le plus élevé
1 = masculin	1 = The Washington Post	1 = quotidien	1 = Sans diplôme
2 = femelle	2 = The New York Times	2 = plusieurs fois par semaine	2 = Collège
	3 = USA Today	3 = plus rarement	3 = Baccalauréat
	4 = ...	4 = jamais	4 = Maîtrise

Définition:

Le test du khi-deux est un test d'hypothèse utilisé pour les variables catégorielles avec une **échelle de mesure** nominale ou ordinale. Le test du khi-deux vérifie si les fréquences observées dans l'échantillon diffèrent

significativement des fréquences attendues. Les fréquences observées sont donc comparées aux fréquences attendues et leurs écarts sont examinés.


	 Femelle	 Masculin
Sans diplôme	6	7
Collège	13	16
Baccalauréat	16	15
Maîtrise	8	11
Total	43	49

Existe-t-il une relation entre le sexe et le niveau d'éducation le plus élevé ?

↓

Test du khi-deux

Supposons que nous voulions étudier s'il existe un lien entre le sexe et le niveau d'éducation le plus élevé. Pour ce faire, nous créons un questionnaire dans lequel les participants cochent leur sexe et leur niveau d'études le plus élevé. Le résultat de l'enquête est ensuite affiché dans un tableau de contingence.



Le test du Khi-deux est utilisé pour déterminer s'il existe une relation entre le sexe et le niveau d'études le plus élevé.

Hypothèse nulle et hypothèse alternative

L'hypothèse nulle et l'hypothèse alternative se traduisent alors par:

Hypothèse nulle: il n'y a pas de relation entre le sexe et le niveau d'éducation le plus élevé.

Hypothèse alternative: Il existe une corrélation entre le sexe et le niveau d'études le plus élevé.

Applications du test du khi-deux

Le test du khi-deux a plusieurs applications. Il peut être utilisé pour répondre aux questions suivantes:

1) Test d'indépendance

Deux variables catégorielles sont-elles indépendantes l'une de l'autre? Par exemple, le sexe a-t-il un impact sur le fait qu'une personne soit abonnée ou non à Netflix?

2) Test de distribution

Les valeurs observées de deux variables catégorielles sont-elles égales aux valeurs attendues? Une question pourrait être la suivante: l'abonnement à l'un des trois services de streaming vidéo Netflix, Amazon et Disney est-il supérieur à la moyenne?

3) Test d'homogénéité

Deux échantillons ou plus sont-ils issus de la même population? Une question pourrait être de savoir si les fréquences d'abonnement aux trois services de streaming vidéo Netflix, Amazon et Disney diffèrent selon les groupes d'âge.

Calculer le khi-deux

La valeur du khi-deux est calculée de la manière suivante:

$$\chi^2 = \sum_{k=1}^n \frac{\overset{\text{Fréquence observée}}{O_k} - \overset{\text{Fréquence attendue}}{E_k}}{E_k}^2$$

Pour clarifier le calcul de la valeur du khi-deux, nous nous référons au cas suivant: Pour les variables 1 et 2 de catégorie A et B, une observation a été faite ou un échantillon existe. Nous voulons maintenant vérifier si les fréquences de l'échantillon correspondent aux fréquences attendues de la population.

Fréquence observée:

	Catégorie A	Catégorie B
Catégorie A	10	13
Catégorie B	13	14

Fréquence attendue:

	Catégorie A	Catégorie B
Catégorie A	9	11
Catégorie B	12	13

Avec la formule ci-dessus, tu peux maintenant calculer le **khi-deux**:

$$\chi^2 = \frac{(10 - 9)^2}{9} + \frac{(13 - 11)^2}{11} + \frac{(13 - 12)^2}{12} + \frac{(14 - 13)^2}{13} = 0.635$$

Après avoir calculé le khi-deux, il faut connaître le nombre de degrés de liberté df. Ce nombre est donné par

$$df = (p - 1)(q - 1) = 1$$

avec

- p : nombre de lignes
- q : nombre de colonnes

À partir du [tableau de la distribution du khi-deux](#), on peut maintenant lire la valeur critique du khi-deux. Pour un niveau de signification de 5 %, on obtient 3,841. Étant

donné que la valeur du khi-deux calculée est plus petite, il n'y a pas de différence significative.

Comme **condition préalable** à ce test, il convient de noter que toutes les fréquences attendues doivent être supérieures à 5.

Test d'indépendance du khi-deux

Le test d'indépendance du khi-deux est utilisé lorsqu'il s'agit de tester l'indépendance de deux variables catégorielles. L'objectif est d'analyser si les valeurs caractéristiques de la première variable sont influencées par les valeurs caractéristiques de la seconde variable et vice versa.

Par exemple, le sexe a-t-il une influence sur le fait qu'une personne soit abonnée ou non à Netflix? Pour les deux variables sexe (homme, femme) et a un abonnement Netflix (oui, non), on teste si elles sont indépendantes. Si ce n'est pas le cas, il existe une relation entre les caractéristiques.

La question de recherche, à laquelle le test du Khi-deux permet de répondre, est la suivante: "Les caractéristiques du sexe et de la possession d'un abonnement Netflix sont-elles indépendantes? Les caractéristiques du sexe et de la possession d'un abonnement Netflix sont-elles indépendantes l'une de l'autre?"

Tableau de distribution du khi-deux

Significance level Alpha	0.995	0.975	0.2	0.1	0.05	0.025	0.02	0.01
Degrés de liberté								
1	0	0.001	1.642	2.706	3.841	5.024	5.412	6.635
2	0.01	0.051	3.219	4.605	5.991	7.378	7.824	9.21
3	0.072	0.216	4.642	6.251	7.815	9.348	9.837	11.345
4	0.207	0.484	5.989	7.779	9.488	11.143	11.668	13.277
5	0.412	0.831	7.289	9.236	11.07	12.833	13.388	15.086
6	0.676	1.237	8.558	10.645	12.592	14.449	15.033	16.812
7	0.989	1.69	9.803	12.017	14.067	16.013	16.622	18.475
8	1.344	2.18	11.03	13.362	15.507	17.535	18.168	20.09
9	1.735	2.7	12.242	14.684	16.919	19.023	19.679	21.666
10	2.156	3.247	13.442	15.987	18.307	20.483	21.161	23.209
11	2.603	3.816	14.631	17.275	19.675	21.92	22.618	24.725
12	3.074	4.404	15.812	18.549	21.026	23.337	24.054	26.217
13	3.565	5.009	16.985	19.812	22.362	24.736	25.472	27.688

Fréquence observée à Berlin:

Service vidéo	Fréquence
Netflix	25
Amazon	29
Disney	13
Autres ou aucun	20

Fréquence attendue (toute l'Allemagne):

Service vidéo	Fréquence
Netflix	23
Amazon	26
Disney	16
Autres ou aucun	22

Le Khi-deux donne alors le résultat suivant

$$\chi^2 = \frac{(25 - 23)^2}{23} + \frac{(29 - 26)^2}{26} + \frac{(13 - 16)^2}{16} + \frac{(20 - 22)^2}{22} = 2.389$$

Test d'homogénéité du Khi-deux

Le test d'homogénéité du Khi-deux peut être utilisé pour vérifier si deux échantillons ou plus proviennent de la même population. Une question pourrait être de savoir si la fréquence d'abonnement à trois services de streaming vidéo (Netflix, Amazon et Disney) diffère selon les groupes d'âge. À titre d'exemple fictif, une enquête est réalisée auprès de trois groupes d'âge et donne les résultats suivants

Les hypothèses pour le test d'indépendance du Khi-deux sont que les observations proviennent d'un échantillon aléatoire et que les fréquences attendues par cellule sont supérieures à 5.

Test de distribution du khi-deux

Si une variable comporte deux valeurs ou plus, les différences de fréquence des valeurs individuelles peuvent être examinées.

Le test de distribution du Khi-deux, ou test d'adéquation, vérifie si les fréquences des valeurs caractéristiques individuelles dans l'échantillon correspondent aux fréquences d'une distribution définie. Dans la plupart des cas, cette distribution définie correspond à celle de la population. Dans ce cas, on vérifie si l'échantillon provient de la population correspondante.

Pour les études de marché, il pourrait être intéressant de savoir s'il existe une différence dans la pénétration du marché des trois services de streaming vidéo Netflix, Amazon et Disney entre Berlin et l'ensemble de l'Allemagne. La fréquence attendue correspond donc à la distribution des services de streaming dans toute l'Allemagne et la fréquence observée résulte d'une enquête menée à Berlin. Les résultats fictifs sont présentés dans les tableaux suivants

Fréquence observée à Berlin:

Service vidéo	Fréquence
Netflix	25
Amazon	29
Disney	13
Autres ou aucun	20

Fréquence attendue (toute l'Allemagne):

Service vidéo	Fréquence
Netflix	23
Amazon	26
Disney	16
Autres ou aucun	22

Le Khi-deux donne alors le résultat suivant

$$\chi^2 = \frac{(25 - 23)^2}{23} + \frac{(29 - 26)^2}{26} + \frac{(13 - 16)^2}{16} + \frac{(20 - 22)^2}{22} = 2.389$$

Test d'homogénéité du Khi-deux

Le test d'homogénéité du Khi-deux peut être utilisé pour vérifier si deux échantillons ou plus proviennent de la même population. Une question pourrait être de savoir si la fréquence d'abonnement à trois services de streaming vidéo (Netflix, Amazon et Disney) diffère selon les groupes d'âge. À titre d'exemple fictif, une enquête est réalisée auprès de trois groupes d'âge et donne les résultats suivants

Fréquence observée:

Âge en années	15-25	25-35	35-45
Netflix	25	23	20
Amazon	29	30	33
Disney	11	13	12
Autres ou aucun	16	24	26

Comme pour le test d'indépendance du Khi-deux, ce résultat est comparé au tableau qui résulterait si les distributions des fournisseurs de streaming étaient indépendantes de l'âge.

Taille de l'effet dans le test du Khi-deux

Jusqu'à présent, nous savons seulement si nous pouvons rejeter l'hypothèse nulle ou non, mais il est souvent très intéressant de savoir quelle est la force de la relation entre les deux variables. On peut répondre à cette question à l'aide de l'intensité de l'effet.

Dans le test du Khi-deux, le V de Cramers peut être utilisé pour calculer l'ampleur de l'effet. Ici, une valeur de 0,1 est petite, une valeur de 0,3 est moyenne et une valeur de 0,5 est grande. DATAtab calcule bien sûr très facilement l'ampleur de l'effet.

Taille de l'effet	V de Cramér
Faible	0.1
Moyen	0.3
Grand	0.5

2-Loi de Student

En [théorie des probabilités](#) et en [statistique](#), la **loi de Student** est une [loi de probabilité](#), faisant intervenir le quotient entre une variable suivant une [loi normale](#) centrée réduite et la [racine carrée](#) d'une variable distribuée suivant la [loi du \$\chi^2\$](#) .

Elle est notamment utilisée pour les [tests de Student](#), la construction d'[intervalle de confiance](#) et en [inférence bayésienne](#).

2-1 Définition

Soit Z une [variable aléatoire](#) de [loi normale](#) centrée et réduite et soit U une [variable indépendante](#) de Z et distribuée suivant la [loi du \$\chi^2\$](#) à k degrés de liberté. Par définition, la variable

$$T = \frac{Z}{\sqrt{U/k}}$$

suit une loi de Student à k degrés de liberté.

$U = \sum_{i=1}^k X_i^2$, alors $U \sim \chi_k^2$, où les X_i sont k [variables aléatoires réelles](#) i.i.d. de [loi normale](#) centrée-réduite.

2-2 Propriétés

2-2-1 Densité de probabilité



La densité de T , notée f_T , est donnée par :

$$f_T(t) = \frac{1}{\sqrt{k\pi}} \frac{\Gamma(\frac{k+1}{2})}{\Gamma(\frac{k}{2})} \left(1 + \frac{t^2}{k}\right)^{-\frac{k+1}{2}}, \text{ pour } k > 0.$$

où Γ est la [fonction Gamma d'Euler](#).

La densité f_T associée à la variable T est symétrique, centrée en 0 et en forme de cloche.

Loi t de Student



2-2-2 Esperance

Son **espérance** ne peut pas être définie pour $k = 1$, et est nulle pour $k > 1$.

2-2-3 Variance

Sa **variance** est infinie pour $k = 2$ et vaut $k/(k - 2)$ pour $k > 2$.

2-2-4 Comportement limite

Lorsque k est grand, la loi de Student converge vers la **loi normale** centrée réduite.


Une manière simple de le démontrer est d'utiliser le **lemme de Scheffé**.

Paramètres	$k > 0$ (degrés de liberté)
Support	$x \in \mathbb{R}$
Densité de probabilité	$f_T(t) = \frac{1}{\sqrt{k\pi}} \frac{\Gamma(\frac{k+1}{2})}{\Gamma(\frac{k}{2})} \left(1 + \frac{t^2}{k}\right)^{-\frac{k+1}{2}}$
Fonction de répartition	$\frac{1}{2} + x\Gamma\left(\frac{k+1}{2}\right) \frac{{}_2F_1\left(\frac{1}{2}, \frac{k+1}{2}; \frac{3}{2}; -\frac{z^2}{k}\right)}{\sqrt{k\pi} \Gamma\left(\frac{k}{2}\right)} \text{ où}$ ${}_2F_1$ est la fonction hypergéométrique
Espérance	• si $k \leq 1$: forme indéterminée • si $k > 1$: 0
Médiane	0
Mode	0
Variance	• si $k \leq 1$: forme indéterminée • si $1 < k \leq 2$: $+\infty$ • si $k > 2$: $\frac{k}{k-2}$
Asymétrie	• si $k \leq 3$: forme indéterminée • si $k > 3$: 0
Kurtosis normalisé	• si $k \leq 2$: forme indéterminée • si $2 < k \leq 4$: $+\infty$ • si $k > 4$: $\frac{6}{k-4}$

2-3 Implémentation de la loi Student(réalisation des test)

Test t

Le test t est une procédure de test statistique qui permet de vérifier s'il existe une différence significative entre les moyennes de deux groupes.



Les deux groupes peuvent être, par exemple, des patients ayant reçu le médicament A une fois et le médicament B une fois, et vous voulez savoir s'il y a une différence de tension artérielle entre ces deux groupes.

Types de test t


Il existe trois types de tests t différents. Le **test t à un échantillon**, le **Test t pour échantillons indépendants** et le **Test t pour échantillons appariés**.

1.



Test t pour un échantillon

2.



Test t pour échantillons indépendants

3.




Test t pour échantillons appariés

Test t à un échantillon

Quand utilise-t-on le **test t à un échantillon**? Nous utilisons le test t à un échantillon lorsque nous voulons comparer la moyenne d'un échantillon à une moyenne de référence connue.


1.

Test t à un échantillon



Exemple de test t à un échantillon


Un fabricant de barres chocolatées affirme que ses barres chocolatées pèsent en moyenne 50 grammes. Pour vérifier cette affirmation, un échantillon de 30 barres est prélevé et pesé. La **valeur moyenne** de cet échantillon est de 48 grammes.



Nous pouvons maintenant effectuer un test t à un échantillon pour voir si la moyenne de 48 grammes est significativement différente des 50 grammes annoncés.


Test t pour les échantillons indépendants

Quand utiliser le **test t pour les échantillons indépendants**? Nous utilisons le test t pour les échantillons indépendants lorsque nous voulons comparer les moyennes de deux groupes ou échantillons indépendants. Nous voulons savoir s'il existe une différence significative entre ces moyennes.



Exemple de test t pour échantillons indépendants

Nous souhaitons comparer l'efficacité de deux analgésiques, le médicament A et le médicament B.



Pour ce faire, nous répartissons au hasard 60 sujets en deux groupes. Le premier groupe reçoit le médicament A, le second le médicament B. Grâce à un test t indépendant, nous pouvons maintenant vérifier s'il existe une différence significative dans le soulagement de la douleur entre les deux médicaments.

Test t pour échantillons appariés

Quand utiliser le [test t pour échantillons dépendants \(test t pour échantillons appariés\)](#)? Le test t pour échantillons dépendants est utilisé pour comparer les moyennes de deux groupes dépendants.



Exemple de test t pour échantillons appariés

Nous voulons connaître l'efficacité d'un régime alimentaire. Pour ce faire, nous pesons 30 personnes avant le régime et exactement les mêmes personnes après le régime.




$$\begin{array}{rcl}
 \text{Icon} & - & \text{Icon} = -5 \\
 \text{Icon} & - & \text{Icon} = +2 \\
 \text{Icon} & - & \text{Icon} = -1 \\
 \text{Icon} & - & \text{Icon} = -3 \\
 \dots & & = \dots
 \end{array}$$

Nous pouvons maintenant voir pour chaque personne quelle est la différence de poids entre avant et après le régime. Avec un test t dépendant, nous pouvons maintenant vérifier s'il y a une différence significative.


Échantillon dépendant ou indépendant

Dans un échantillon dépendant (échantillon apparié), les valeurs mesurées sont disponibles par paires. Les paires sont créées, par exemple, par des mesures répétées sur les mêmes personnes. Les échantillons indépendants (échantillons indépendants) résultent de personnes et de mesures indépendantes les unes des autres.



À noter : le test t pour les échantillons dépendants n'est pas disponible pour les échantillons indépendants.

Le test t pour les échantillons dépendants est très similaire au test t pour un échantillon. Nous pouvons également considérer le test t pour les échantillons dépendants comme un échantillon mesuré à deux moments différents. Nous calculons ensuite la différence entre les valeurs appariées et obtenons une valeur pour un échantillon.



Nous obtenons une fois -5, une fois +2, une fois -1 et ainsi de suite. Nous voulons maintenant vérifier si la moyenne s'écarte de la différence calculée jusqu'à une valeur de référence. Dans ce cas, zéro. C'est exactement ce que fait le test t pour un échantillon.


Hypothèses

Quelles sont les hypothèses pour pouvoir calculer un test t en premier lieu ? Tout d'abord, bien sûr, nous devons disposer d'un échantillon approprié.

- Pour le test t à un échantillon, nous avons besoin d'un échantillon et d'une valeur de référence.
- Dans un test t indépendant, nous avons besoin de deux échantillons indépendants.
- Et pour le test t pour échantillons appariés, nous avons besoin d'un échantillon dépendant.

La variable pour laquelle il s'agit de vérifier s'il existe une différence entre les moyennes doit être métrique. Les variables métriques sont par exemple l'âge, le poids corporel, le revenu. Une variable non métrique est, par exemple, le diplôme de fin d'études d'une personne (Hauptschule, Realschule,...).

En outre, la variable métrique doit être normalement distribuée dans les trois variantes du test t.



Vous pouvez découvrir comment tester si vos données sont normalement distribuées dans mon tutoriel sur les [tests de distribution normale](#).

Pour le test t dépendant, les variances des deux groupes doivent encore être approximativement égales. Vous pouvez vérifier si les variances sont égales à l'aide du [test de Levene](#).

Hypothèses

Quelles sont donc les [hypothèses](#) pour le test t ? Commençons par le test t à un échantillon.

Test t pour un échantillon

Dans le test t pour un échantillon, l'hypothèse nulle et l'hypothèse alternative sont :

- **Hypothèse nulle** : La moyenne de l'échantillon est égale à la valeur de référence donnée (il n'y a donc pas de différence).
- **Hypothèse alternative** : La moyenne de l'échantillon n'est pas égale à la valeur de référence donnée (il y a donc une différence).

Test t pour les échantillons indépendants

Qu'en est-il du test t pour les échantillons indépendants ? Dans le test t pour échantillons indépendants, l'hypothèse nulle est la suivante :

- **Hypothèse nulle** : Les moyennes des deux groupes sont égales (il n'y a donc pas de différence entre les deux groupes).
- **Hypothèse alternative** : Les valeurs moyennes des deux groupes ne sont pas égales (il y a donc une différence entre les deux groupes).

Test t pour les échantillons appariés

Enfin, le test t pour les échantillons appariés. Dans le test t pour échantillons appariés, l'hypothèse nulle est la suivante :


- **Hypothèse nulle** : La moyenne de la différence entre les paires est nulle.
- **Hypothèse alternative** : La moyenne de la différence entre les paires n'est pas nulle.

Pourquoi avons-nous besoin d'un test t ?

Supposons que nous ayons formulé une hypothèse :


Il existe une différence dans la durée des études entre les hommes et les femmes en Allemagne.

Notre population de base est donc constituée de tous les diplômés d'un programme diplômant en Allemagne. Comme nous ne pouvons évidemment pas enquêter auprès de tous les diplômés, nous tirons un échantillon aussi représentatif que possible.



Avec le test t, nous testons maintenant l'hypothèse nulle selon laquelle il n'y a pas de différence dans la population.

S'il n'y a pas de différence dans la population, nous verrons certainement une différence dans la durée des études dans l'échantillon. Il serait très improbable que nous tirions un échantillon où la différence est exactement nulle.




En termes simples, nous voulons maintenant savoir à partir de quelle différence, mesurée dans l'échantillon, nous pouvons dire que la durée des études des hommes et des femmes est significativement différente. Et c'est exactement ce à quoi répond le test t.

Calculer le test t


Comment calculer un test t ? Il faut d'abord calculer la valeur t :

Pour calculer la valeur t, nous avons besoin de deux valeurs. Premièrement, nous avons besoin de la différence des moyennes et deuxièmement, de l'écart-type par rapport à la moyenne. Cette valeur est appelée l'erreur standard.




$$t = \frac{\text{Différence entre les valeurs moyennes}}{\text{Écart-type par rapport à la moyenne}}$$

Dans le test t sur échantillon, nous calculons la différence entre la moyenne de l'échantillon et la moyenne de référence connue. s est l'écart-type des données collectées et n est le nombre de cas.



$$t = \frac{\bar{x} - \mu}{\frac{s}{\sqrt{n}}}$$

s divisé par la racine carrée de n est alors l'écart-type de la moyenne ou l'erreur-type.



$$t = \frac{\bar{x} - \mu}{\boxed{\frac{s}{\sqrt{n}}}}$$

Erreur standard

Dans le test t pour les échantillons indépendants, la différence est simplement calculée à partir de la différence des moyennes des deux échantillons.

Diagram illustrating the formula for the t-test for independent samples. The formula is:

$$t = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

Labels and arrows indicate the components:

- $\bar{X}_1$: Moyenne échantillon 1
- $\bar{X}_2$: Moyenne de l'échantillon 2
- s_1^2 and s_2^2 : Écart-type Échantillons 1 et 2
- n_1 and n_2 : Nombre de cas Échantillon 1 et 2

Pour calculer l'erreur standard, nous avons besoin de l'écart type et du nombre de cas du premier et du second échantillon.

Selon que nous pouvons supposer des variances égales ou inégales pour nos données, il existe différentes formules pour l'erreur standard. Pour en savoir plus, consultez le [didacticiel sur le test t pour les échantillons indépendants](#).

Dans le cas d'un test t pour échantillons appariés, il suffit de calculer la différence des valeurs appariées et d'en déduire la moyenne. L'erreur standard est alors la même que dans le cas d'un test t pour un échantillon.

Diagram illustrating the formula for the t-test for paired samples. The formula is:


$$t = \frac{\bar{X}_d - 0}{\frac{s}{\sqrt{n}}}$$

Labels and arrows indicate the components:

- $\bar{X}_d$: Moyenne de la différence
- s : Écart-type
- n : Nombre de cas

Interpréter t-valu

Quel que soit le test t que nous calculons, la valeur t est d'autant plus grande que la différence entre les moyennes est importante. De même, la valeur t devient plus petite lorsque la différence entre les moyennes est plus faible.



De même, la valeur t devient plus petite si la dispersion des valeurs moyennes est plus importante. Ainsi, plus les données sont dispersées, moins une différence de moyenne donnée a d'importance !

La valeur t et l'hypothèse nulle

Nous voulons maintenant utiliser le test t pour savoir si nous rejetons ou non l'hypothèse nulle. Pour ce faire, nous pouvons utiliser la valeur t de deux manières. Soit nous lisons la valeur t dite critique dans un tableau, soit nous calculons simplement la valeur p à l'aide de la valeur t.



1.

Lire la valeur t critique



2.

Calculer la valeur p

Commençons par la méthode de la valeur t critique, que nous pouvons lire dans un tableau. Pour ce faire, nous avons d'abord besoin du [tableau des valeurs t critiques](#), que nous pouvons trouver sur [datatab.net](#) sous Tutoriels et Distribution t.

Commençons par le cas bilatéral, qui est une hypothèse unilatérale ou dirigée. Vous trouverez ci-dessous le tableau.

Tableau Valeur t

Zone bilatérale											
ddl	0	0.5	0.6	0.7	0.8	0.9	0.95	0.98	0.99	0.998	0.999
1	0	1	1.376	1.963	3.078	6.314	12.71	31.82	63.66	318.31	636.62
2	0	0.816	1.061	1.386	1.886	2.92	4.303	6.965	9.925	22.327	31.599
3	0	0.765	0.978	1.25	1.638	2.353	3.182	4.541	5.841	10.215	12.924
4	0	0.741	0.941	1.19	1.533	2.132	2.776	3.747	4.604	7.173	8.61
5	0	0.727	0.92	1.156	1.476	2.015	2.571	3.365	4.032	5.893	6.869
6	0	0.718	0.906	1.134	1.44	1.943	2.447	3.143	3.707	5.208	5.959
7	0	0.711	0.896	1.119	1.415	1.895	2.365	2.998	3.499	4.785	5.408
8	0	0.706	0.889	1.108	1.397	1.86	2.306	2.896	3.355	4.501	5.041
9	0	0.703	0.883	1.1	1.383	1.833	2.262	2.821	3.25	4.297	4.781
10	0	0.7	0.879	1.093	1.372	1.812	2.228	2.764	3.169	4.144	4.587
11	0	0.697	0.876	1.088	1.363	1.796	2.201	2.718	3.106	4.025	4.437
12	0	0.695	0.873	1.083	1.356	1.782	2.179	2.681	3.055	3.93	4.318

Nous devons d'abord déterminer le niveau de signification que nous voulons utiliser. Ici, nous choisissons un niveau de signification de 0,05, c'est-à-dire 5 %. Ensuite, nous devons regarder dans la colonne à 1-0,05, donc à 0,95.

Nous devons d'abord déterminer le niveau de signification que nous voulons utiliser. Ici, nous choisissons un niveau de signification de 0,05, c'est-à-dire 5 %. Ensuite, nous devons regarder dans la colonne à 1-0,05, donc à 0,95.

Nous avons maintenant besoin des degrés de liberté. Dans le test t à un échantillon et le test t à un échantillon dépendant, les degrés de liberté sont simplement le nombre de cas moins 1. Ainsi, si nous disposons d'un échantillon de 10 personnes, nous avons 9 degrés de liberté. Dans le test t pour échantillons indépendants, nous additionnons le nombre de personnes des deux échantillons et calculons moins 2 car nous avons deux échantillons. Il convient de noter que les degrés de liberté peuvent également être déterminés d'autres manières, selon que l'on suppose une variance égale ou inégale.

Degrés de liberté

Test t à un
échantillon

$$ddl = n - 1$$

Test t sur échantillons
indépendants

$$ddl = n_1 + n_2 - 2$$

Test t par
paire

$$ddl = n - 1$$

Ainsi, si nous avons un niveau de signification de 5 % et 9 degrés de liberté, nous obtenons une valeur t critique de 2,262.

D'une part, nous avons calculé une valeur t avec le test t et, d'autre part, nous avons la valeur t critique. Si la valeur t calculée est supérieure à la valeur t critique, nous rejetons l'hypothèse nulle. Supposons que nous ayons calculé une valeur t de 2,5. Cette valeur est supérieure à 2,262 et les deux moyennes sont donc tellement éloignées l'une de l'autre que nous pouvons rejeter l'hypothèse nulle.

D'autre part, nous pouvons également calculer la valeur p pour la valeur t que nous avons calculée. Si nous entrons 2,5 pour la valeur t et 9 pour les degrés de liberté, nous obtenons une valeur p de 0,034. La valeur p est inférieure à 0,05 et nous rejetons donc également l'hypothèse nulle de cette manière.

Unilatéral

Bilatéral

Probabilité d'erreur

Valeur t

df

Valeur p

2,5

9

= 0,0339

Valeur t critique

alpha


df

Valeur t

0,05

9

= 2,262



À titre de vérification, si nous copions la valeur t de 2,262 ici, nous obtenons exactement une valeur p de 0,05, ce qui correspond exactement à la limite.

Unilatéral

Bilatéral

Probabilité d'erreur

Valeur t

df

Valeur p

2,262

9

= 0,05

Valeur t critique

alpha


df

Valeur t

0,05

9

= 2,262



Test t avec DATAtab berechnen

Si vous souhaitez **calculer un test t avec DATAtab**, il vous suffit de copier vos propres données dans ce tableau, de cliquer sur Test d'hypothèse et de sélectionner les variables souhaitées.

	nominal	métrique	métrique	nominal	métrique	nominal	ordinal
Cas	Genre	Salaire	Âge	Ville	Poids	Entreprise	Diplôme université
1	Femme	1500	33	Marseille	80	Renault	Licence
2	Femme	1200	33	Marseille	82,5	Peugeot	Néant
3	Homme	2200	34	Paris	100,8	Renault	Licence
4	Homme	2100	42	Paris	90	Renault	Master
5	Femme	1500	29	Marseille	67	Peugeot	Master
6	Femme	1700	19	Lyon	60	Peugeot	Master
7	Homme	3000	50	Lyon	77	Peugeot	Néant
8	Homme	3000	55	Lyon	77	Peugeot	Licence
9	Femme	2800	31	Paris	87	Peugeot	Licence
10	Homme	2900	46	Paris	70	Citroen	Master
11	Femme	2780	36	Lyon	57	Renault	Néant
12	Homme	2550	48	Paris	64	Citroen	Master
13							
14							
15							

Descriptive Gráficos **Pruebas de hipótesis** Corrélation Régression Mediación/Moderación PCA Fiabilidad Clasificación +

Variables métriques:

☒ Salaire ☐ Âge ☐ Poids

Variables ordinales:

☐ Diplôme universitaire

Variables nominales:

☒ Genre ☐ Ville ☐ Entreprise

Par exemple, si vous souhaitez vérifier si le sexe a une influence sur le revenu, il vous suffit de cliquer sur les deux variables et un test t pour échantillons indépendants est automatiquement calculé. Vous pouvez ensuite lire la valeur p en bas du tableau.

Test t pour les échantillons indépendants

[Vérifier les hypothèses](#)[Résumé en mots](#)

Hypothèses

[Copie](#) [Paramètres](#)**Hypothèse nulle**

Il n'y a pas de différence entre les groupes Femme et Homme en ce qui concerne la variable dépendante Salaire.

Hypothèse alternative


Il existe une différence entre les groupes Femme et Homme en ce qui concerne la variable dépendante Salaire.

Descriptive statistics

[Copie](#) [Paramètres](#)

		n	Moyenne	Écart-type	Erreur type de la moyenne
Salaire	Femme	6	1913,33	697,61	284,8
	Homme	6	2625	404,66	165,2

Graphique en boîtes

Orientation☒ Verticale☐ Horizontale**Afficher les points**☐ Oui☒ Non**Écart-type**☐ Oui☒ Non**Taille du graphique**☐ Petit☒ Moyen☐ Grand☐ Très grand[Télécharger png](#) [Télécharger svg](#) [Paramètres](#)[Click to enter Plot title](#)

Test de Levene de l'égalité de la variance

Copie Paramètres

	F	ddl1	ddl2	p
Test de Levene (Moyenne)	3,52	1	10	,09
Test de Brown-Forsythe (Médiane)	0,55	1	10	,477

Test t pour les échantillons indépendants

Copie Paramètres

		t	ddl	p	Taille de l'effet d
Salaire	Variations égales	-2,16	10	,056	1,25
	Variances inégales	-2,16	8,02	,063	1,25

95% Intervalle de confiance de la différence

Copie Paramètres

		Différence moyenne	Erreur type de la différence	Limite inférieure	Limite supérieure
Salaire	Variations égales	-711,67	329,25	-1445,23	21,89
	Variances inégales	-711,67	329,25	-1470,58	47,25

Si vous ne savez toujours pas comment interpréter les résultats, il vous suffit de cliquer sur Interprétation en toutes lettres :

Un test t bilatéral pour échantillons indépendants (variances égales supposées) a montré que la différence entre Femmes et Hommes en ce qui concerne la variable dépendante Salaire n'était pas statistiquement significative, $t(10) = -2,16$, $p = .056$, intervalle de confiance à 95 % [-1445,23, 21,89]. L'hypothèse nulle est donc maintenue.

Hypothèse dirigée et non dirigée

La dernière question qui se pose maintenant est de savoir quelle est la différence entre une hypothèse unilatérale ou dirigée et une hypothèse bilatérale ou non dirigée. Dans le cas non dirigé, l'hypothèse alternative est qu'il existe une différence, par exemple qu'il existe une différence entre les salaires des hommes et des femmes.

10	Homme	2900	46	Paris	70	Citroen	Master	
11	Femme	2780	36	Lyon	57	Renault	Néant	
12	Homme	2550	48	Paris	64	Citroen	Master	
13								
14								
15								

Descriptive Gráficos Pruebas de hipótesis Correlación Régression Mediación/Moderación PCA Fiabilidad Clasificación +

Variables métriques:

☒ Salaire ☐ Âge ☐ Poids

Variables ordinales:

☐ Diplôme universitaire

Variables nominales:

☒ Genre ☐ Ville ☐ Entreprise



☒ Test paramétrique ☐ Test non-paramétrique

Hypothèse alternative

☒ Femme ≠ Homme

☐ Femme > Homme

☐ Femme < Homme

Signification statistique

0,05

Test t pour les échantillons indépendants

Vérifier les hypothèses

Résumé en mots

Hypothèses

Copie Paramètres

Hypothèse nulle

Il n'y a pas de différence entre les groupes Femme et Homme en ce qui concerne la variable dépendante Salaire.

Hypothèse alternative

Il existe une différence entre les groupes Femme et Homme en ce qui concerne la variable dépendante Salaire.

Dans ce cas, nous ne nous intéressons pas à savoir lequel des deux gagne le plus, nous voulons seulement savoir s'il y a une différence ou non. Dans le cas d'une hypothèse dirigée, nous nous intéressons également au sens de la différence. L'hypothèse alternative est alors, par exemple, que les hommes gagnent plus que les femmes ou que les femmes gagnent plus que les hommes.

Si nous examinons cette question sous forme de graphique avec la distribution t, nous constatons que dans le cas bilatéral, nous avons une fois une fourchette à gauche et une fois une fourchette à droite. Nous voulons rejeter l'hypothèse nulle si nous nous trouvons ici ou là. À un niveau de signification de 5 %, les deux plages ont une probabilité de 2,5 %, de sorte qu'ensemble, elles ont 5 %.

Lorsque nous effectuons un test t unilatéral, nous ne rejetons l'hypothèse nulle que si nous nous trouvons dans cet intervalle, ou selon le signe que nous testons dans cet intervalle. Avec un niveau de signification de 5 %, l'ensemble des 5 % se situe dans cette fourchette.

Unilatéral

Bilatéral

Probabilité d'erreur

Valeur t

1,833

df

9

Valeur p

= 0,05

Valeur t critique

alpha


0,05

df

9

Valeur t

= 1,833



2-Loi de Fisher

En [théorie des probabilités](#) et en [statistiques](#), la **loi de Fisher** ou encore **loi de Fisher-Snedecor** ou encore **loi F de Snedecor** est une [loi de probabilité continue](#)^{[1],[2],[3]}. Elle tire son nom des statisticiens [Ronald Aylmer Fisher](#) et [George Snedecor](#).

La loi de Fisher survient très fréquemment en tant que loi de la [statistique de test](#) lorsque l'[hypothèse nulle](#) est vraie, dans des [tests statistiques](#), comme les tests du ratio de [vraisemblance](#), dans les [tests de Chow](#) utilisés en économétrie, ou encore dans l'[analyse de la variance](#) (ANOVA) via le [test de Fisher](#).

2-1 Caractérisation

Une **variable aléatoire réelle** distribuée selon la loi de Fisher peut être construite comme le quotient de deux variables aléatoires **indépendantes**, U_1 et U_2 , distribuées chacune selon une **loi du χ^2** et ajustées pour leurs nombres de **degrés de liberté**, respectivement d_1 et d_2 :

$$F(d_1, d_2) \sim \frac{U_1/d_1}{U_2/d_2}.$$

La **densité de probabilité** d'une loi de Fisher, $F(d_1, d_2)$, est donnée par

$$f(x) = \frac{\left(\frac{d_1 x}{d_1 x + d_2}\right)^{d_1/2} \left(1 - \frac{d_1 x}{d_1 x + d_2}\right)^{d_2/2}}{x B(d_1/2, d_2/2)}$$

pour tout **réel** $x \geq 0$, où d_1 et d_2 sont des entiers positifs et B est la **fonction bêta**.

La **fonction de répartition** associée est :

$$F(x) = I_{\frac{d_1 x}{d_1 x + d_2}}(d_1/2, d_2/2)$$

où I est la **fonction bêta incomplète régularisée**.

La **loi binomiale** est liée à la loi de Fisher par la propriété suivante⁴ : si X suit une loi binomiale de paramètres n et p , et si k est un entier compris entre 0 et n , alors $\mathbb{P}(X \leq k) = \mathbb{P}(F \geq x)$ où F suit une loi de Fisher de paramètres

$$d_1 = 2(k + 1), d_2 = 2(n - k) \text{ avec } x = \frac{n - k}{k + 1} \cdot \frac{p}{1 - p}.$$

L'espérance, la variance valent respectivement


$$\frac{d_2}{d_2 - 2}$$

pour $d_2 > 2$ et


$$\frac{2 d_2^2 (d_1 + d_2 - 2)}{d_1 (d_2 - 2)^2 (d_2 - 4)} \text{ pour } d_2 > 4. \text{ Pour } d_2 > 8, \text{ le kurtosis normalisé est}$$

$$\gamma_2 = 12 \frac{d_1 (5d_2 - 22)(d_1 + d_2 - 2) + (d_2 - 4)(d_2 - 2)^2}{d_1 (d_2 - 6)(d_2 - 8)(d_1 + d_2 - 2)}.$$

Fisher-Snedecor



Densité de probabilité



Fonction de répartition

Paramètres	$d_1 > 0, d_2 > 0$ degré de liberté
Support	$x \in [0, +\infty[$
Densité de probabilité	$\frac{\sqrt{\frac{(d_1 x)^{d_1} d_2^{d_2}}{(d_1 x + d_2)^{d_1 + d_2}}}}{x B\left(\frac{d_1}{2}, \frac{d_2}{2}\right)}$
Fonction de répartition	$I_{\frac{d_1 x}{d_1 x + d_2}}(d_1/2, d_2/2)$
Espérance	$\frac{d_2}{d_2 - 2}$ pour $d_2 > 2$
Mode	$\frac{d_1 - 2}{d_1} \frac{d_2}{d_2 + 2}$ pour $d_1 > 2$
Variance	$\frac{2 d_2^2 (d_1 + d_2 - 2)}{d_1 (d_2 - 2)^2 (d_2 - 4)}$ pour $d_2 > 4$
Asymétrie	$\frac{(2d_1 + d_2 - 2)\sqrt{8(d_2 - 4)}}{(d_2 - 6)\sqrt{d_1(d_1 + d_2 - 2)}}$ pour $d_2 > 6$
Kurtosis normalisé	$12 \frac{d_1(5d_2 - 22)(d_1 + d_2 - 2) + (d_2 - 4)(d_2 - 2)^2}{d_1(d_2 - 6)(d_2 - 8)(d_1 + d_2 - 2)}$ pour $d_2 > 8$

2-2 Caractérisation

- Si $X \sim F(d_1, d_2)$ alors $Y = \lim_{d_2 \rightarrow \infty} d_1 X$ est distribuée selon une [loi du \$\chi^2\$](#) $\chi_{d_1}^2$;
- La loi $F(d_1, d_2)$ est équivalente à la loi T^2 de Hotelling $(d_1(d_1 + d_2 - 1)/d_2) T^2(d_1, d_1 + d_2 - 1)$;
- Si $X \sim F(d_1, d_2)$, alors la [loi inverse](#) est aussi une loi de Fisher $\frac{1}{X} \sim F(d_2, d_1)$;
- Si $X \sim t(d)$ est distribuée selon une [loi de Student](#) alors $X^2 \sim F(1, d)$;
- Si $X \sim \mathcal{N}(0, 1)$ est distribuée selon une [loi normale](#) alors $X^2 \sim F(1, \infty)$;
- Si $X \sim F(d_1, d_2)$ et $Y = \frac{d_1 X / d_2}{1 + d_1 X / d_2}$ alors $Y \sim \text{Beta}(d_1/2, d_2/2)$ est distribuée selon une [loi bêta](#);
- Si $Q_X(p)$ est le quantile d'ordre p pour $X \sim F(d_1, d_2)$ et que $Q_Y(p)$ est le quantile d'ordre p pour $Y \sim F(d_2, d_1)$ alors $Q_X(p) = 1 / Q_Y(1 - p)$.

2-3 Table de valeurs des quantiles

Le tableau suivant fournit les valeurs de certains quantiles de la loi de Fisher pour différents paramètres v_1 et v_2 . Pour chaque paramètre, le quantile donné est tel que la probabilité pour qu'une variable suivant une loi de Fisher lui soit inférieur est de $1 - \alpha$. Ainsi, pour $1 - \alpha = 0,95$ et $d_1 = 1$ et $d_2 = 3$, si X suit une loi de Fisher avec ces paramètres, on lit dans la table que $P(X \leq 10,13) = 0,95$.




Table de Fisher-Snedecor, $1-\alpha = 0.95$

Taille du texte

d_2 (dén.)	d_1 (numérateur)																	
	1	2	3	4	5	6	7	8	9	10	20	30	40	50	60	80	100	200
1	161.45	199.50	215.71	224.58	230.16	233.99	236.77	238.88	240.54	241.88	248.02	250.10	251.14	251.77	252.20	252.72	253.04	253.68
2	18.51	19.00	19.16	19.25	19.30	19.33	19.35	19.37	19.38	19.40	19.45	19.46	19.47	19.48	19.48	19.48	19.49	19.49
3	10.13	9.55	9.28	9.12	9.01	8.94	8.89	8.85	8.81	8.79	8.66	8.62	8.59	8.58	8.57	8.56	8.55	8.54
4	7.71	6.94	6.59	6.39	6.26	6.16	6.09	6.04	6.00	5.96	5.80	5.75	5.72	5.70	5.69	5.67	5.66	5.65
5	6.61	5.79	5.41	5.19	5.05	4.95	4.88	4.82	4.77	4.74	4.56	4.50	4.46	4.44	4.43	4.41	4.41	4.39
6	5.99	5.14	4.76	4.53	4.39	4.28	4.21	4.15	4.10	4.06	3.87	3.81	3.77	3.75	3.74	3.72	3.71	3.69
7	5.59	4.74	4.35	4.12	3.97	3.87	3.79	3.73	3.68	3.64	3.44	3.38	3.34	3.32	3.30	3.29	3.27	3.25
8	5.32	4.46	4.07	3.84	3.69	3.58	3.50	3.44	3.39	3.35	3.15	3.08	3.04	3.02	3.01	2.99	2.97	2.95
9	5.12	4.26	3.86	3.63	3.48	3.37	3.29	3.23	3.18	3.14	2.94	2.86	2.83	2.80	2.79	2.77	2.76	2.73
10	4.96	4.10	3.71	3.48	3.33	3.22	3.14	3.07	3.02	2.98	2.77	2.70	2.66	2.64	2.62	2.60	2.59	2.56
20	4.35	3.49	3.10	2.87	2.71	2.60	2.51	2.45	2.39	2.35	2.12	2.04	1.99	1.97	1.95	1.92	1.91	1.88
30	4.17	3.32	2.92	2.69	2.53	2.42	2.33	2.27	2.21	2.16	1.93	1.84	1.79	1.76	1.74	1.71	1.70	1.66
40	4.08	3.23	2.84	2.61	2.45	2.34	2.25	2.18	2.12	2.08	1.84	1.74	1.69	1.66	1.64	1.61	1.59	1.55

Applications

- Si on considère que la mesure de pollution d'un véhicule de marque donnée suit $X_1 \sim \mathcal{N}(c_0, \sigma_0^2)$, alors

$$\begin{aligned} \mathbb{P}(\bar{X} \geq 6.43) &= \mathbb{P}\left(\frac{\bar{X} - c_0}{\sigma_0/\sqrt{n}} \geq \frac{6.43 - c_0}{\sigma_0/\sqrt{n}}\right) \\ &= 1 - F_{\mathcal{N}}\left(\underbrace{\frac{6.43 - c_0}{\sigma_0/\sqrt{n}}}_{2.87}\right) \simeq 0.002 \end{aligned}$$

- On peut aussi se demander quelle valeur q de consommation moyenne sur 30 véhicules est dépassée avec une probabilité donnée (par ex, $\alpha = 5\%$)

$$\mathbb{P}(\bar{X} \geq q) = 1 - F_{\mathcal{N}}\left(\frac{q - c_0}{\sigma_0/\sqrt{n}}\right) = 0.05$$

$$\text{Soit } q = c_0 + \underbrace{F_{\mathcal{N}}^{-1}(0.95)}_{\text{quantile d'ordre 95\% de } \mathcal{N}(0,1)} \frac{\sigma_0}{\sqrt{n}} = 6.38$$

2-Loi Gamma

On dit que la variable aléatoire X suit la **loi gamma** de paramètres $p > 0$ et $\lambda > 0$, notée $\Gamma(p, \lambda)$, si elle admet pour densité

$$f(x) = \begin{cases} \frac{\lambda}{\Gamma(p)} e^{-\lambda x} (\lambda x)^{p-1} & \text{si } x > 0 \\ 0 & \text{sinon.} \end{cases}$$


Une telle variable aléatoire X admet alors une espérance et une variance donnés par

$$E(X) = \frac{p}{\lambda} \text{ et } V(X) = \frac{p}{\lambda^2}$$

tandis que sa fonction caractéristique est

$$\phi_X(t) = \left(\frac{\lambda}{\lambda - it} \right)^p.$$

Courbe représentative de la densité (cas $p = 2$ et $\lambda = 1$) :



Signification : La durée de vie d'un appareil ou d'un organisme suit souvent, quand le vieillissement intervient et donc que le taux de défaillance augmente, une loi $\Gamma(p, \lambda)$ avec $p > 1$. Remarquons que la loi $\Gamma(1, \lambda)$ n'est autre que la loi exponentielle $\mathcal{E}(\lambda)$ qui s'utilise pour modéliser des durées de vie sans vieillissement.

Lorsque p est un entier, la loi gamma s'appelle encore **loi d'Erlang**. La loi d'Erlang de paramètre p et λ est la loi de la somme de p variables aléatoires indépendantes suivant une même loi exponentielle de paramètre λ . A ce titre, elle est la loi du temps d'attente séparant la survenue des événements k et $k+p$ dans un processus poissonien, par exemple une succession de pannes à taux de défaillance constant.

Lorsque $p = n/2$ et $\lambda = 1/2$, on retrouve la loi du khi-deux à n degrés de liberté, c'est-à-dire la loi de la somme des carrés de n variables aléatoires indépendantes suivant chacune une loi normale.

conclusion

Ce mini-projet a offert une exploration approfondie des lois de Khi-deux, Student, Fisher et Gamma, mettant en lumière leur importance fondamentale en statistique inférentielle et en modélisation probabiliste. À travers une approche à la fois théorique et pratique, nous avons développé des outils interactifs permettant de visualiser et de manipuler ces distributions, facilitant ainsi leur compréhension et leur application dans des contextes variés.

La réalisation de ce projet a permis de consolider des compétences techniques en programmation web et en visualisation de données, tout en renforçant la maîtrise des concepts statistiques sous-jacents. Les applications concrètes illustrées, comme les tests d'hypothèses ou la modélisation de phénomènes continus, démontrent l'utilité opérationnelle de ces lois dans des situations réelles d'analyse de données.

Ce travail ouvre des perspectives intéressantes pour des développements futurs, notamment l'intégration de ces outils dans des plateformes pédagogiques ou l'extension à d'autres distributions probabilistes. Il constitue une base solide pour des applications plus avancées en statistique computationnelle et en science des données.